

Data Analysis Using R: Chapter2

罗智超 *Rokia.org*

Contents

内容简介	1
R 语言自带数据	1
Anscombe 数据	2
查看数据集	2
查看数据集	2
数据集的基本元素	2
什么是 tidy 数据格式	3
tidy data Rule	3
如何更改 Anscombe 数据的格式	3
如何绘图	3
代码分析	3
扩展案例	3
Tidy data Case	3
Values in column names	3
Variable names in cells	4
Weather data	4
titanic2	4
课后练习	5
本周“大牛”	5

内容简介

- 通过案例了解 R 语言的基本特点
- 了解数据集的结构
- 通过案例了解简单回归代码

R 语言自带数据

- R 里面自带了很多数据集，这样方便研究人员验证算法
- 通过 `data()` 可以查阅所有数据集名称
- 通过 `data(package="packagename")` 来查阅 R 包里面自带的数据集名称

```
data()
#sample data faithful,Titanic,iris,mtcars,flight
f<-faithful
View(f)
str(f)
hist(f$eruptions,breaks = 20)
hist(f$waiting,breaks=20)
t<-Titanic
head(iris)
```

Anscombe 数据

- 1973 年，统计学家 F.J. Anscombe 在 Graphs in Statistical Analysis 构造出了四组奇特的数据。它告诉人们，在分析数据之前，描绘数据所对应的图像有多么的重要。
- 本章通过对 R 自带的的 Anscombe 数据进行简单的处理，让同学了解 R 语言的基本特征

查看数据集

```
anscombe
# 练习：计算所有变量的均值方差，并绘制每个变量的频数分布图、盒形图、以及每组变量的散点图 ( x1*y1,x2*y2)
str(anscombe) #x1-x4,y1-y4

m<-apply(anscombe,2,mean)
v<-apply(anscombe,1,var)

hist(anscombe$x1)

plot(anscombe$x1,anscombe$y1)
plot(anscombe$x2,anscombe$y2)
plot(anscombe$x3,anscombe$y3)
plot(anscombe$x4,anscombe$y4)
# 思考，如何转变数据结构使得可以使用下面伪代码方法
plot(x,y,by=group)

?anscombe
# 思考如何把四张图画在一张图里面

View(anscombe)
```

查看数据集

- 看看数据集的结构有什么特征
- 计算下各个变量的统计值
- 基本绘图

数据集的基本元素

- 变量 (variable name)

- 记录 (column name)
- 变量类型 (数值、字符、因子)

什么是 tidy 数据格式

- Hadley 发表在 Journal of statistical software 上的文章Tidy Data
- 该文章的源码地址
- 宽数据 VS 窄数据

tidy data Rule

- Each variable forms a column.
- Each observation forms a row.
- Each type of observational unit forms a table.

如何更改 Anscombe 数据的格式

- 方法一 (R BASE 函数)
- 方法二 (library(dplyr))
- 方法三 (循环)
- 方法四 (library(reshape2))

如何绘图

- 方法一 (基于原始数据格式)
- 方法二 (基于 tidy 数据格式)

代码分析

- anscombe.r

扩展案例

- 考试成绩的回归分析

Tidy data Case

Values in column names

– Income distribution within U.S. religious groups

```

#Collected by Pew Research Center
#Examines the relationship between income and religion in the US
#i.e, which religions have the wealthiest adherents?
# 计算不同宗教哪个水平工资的人数最多
library(reshape2)
raw <- read.csv("data/pew.csv", check.names = F)
tidy <- melt(raw, id = "religion")
View(tidy)
# We can now fix the column names
names(tidy) <- c("religion", "income", "n")
# Alternatively
tidy <- melt(raw, id = "religion", variable.name = "income", value.name = "n")
View(tidy)

```

Variable names in cells

Weather data

```

#Daily temperatures in Cuernavaca, Mexico for 2010
#1 - 31, days of month
#tmax, tmin, maximum and minimum temperatures
# 计算每天最低气温和最高气温的差值
raw <- read.delim("data/weather.txt", check.names = F, na.strings = ".")
View(raw)
# na.rm = TRUE is useful if the missing values don't have any meaning
raw.tidy <- melt(raw, id = c("year", "month", "element"), variable.name = "day", na.rm = TRUE)
# reordering columns
raw <- raw.tidy[, c("year", "month", "day", "element", "value")]
head(raw)
tidy <- dcast(raw, year + month + day ~ element, value.var = "value")
head(tidy)

```

titanic2

```

# 思考下如何通过原始表, 计算存活率
titanic2 <- read.csv("data/titanic2.csv", stringsAsFactors = FALSE)
head(titanic2)
# 计算不同类别的存活率 = 存活人数 / ( 存活人数 + 死亡人数 )
#Step 1
tidy <- melt(titanic2, id = c("class", "age", "fate"), variable.name = "gender")
head(tidy)
#Step 2
tidy <- dcast(tidy, class + age + gender ~ fate, value.var = "value")
head(tidy)
#Step 3
tidy$rate <- round(tidy$survived / (tidy$survived + tidy$perished), 2)
head(tidy)

```

课后练习

```
#Forbes2013 top 2000 company
#Statistics by Wuxizhi P13
w<-read.csv("data/Forbes2000.csv")
names(w)
summary(w)
View(w)
w[w[,3]=="China",2]
par(mfrow=c(2,2))
for(i in 4:7)
{
  hist(log(w[,i]),main=paste("Log",names(w)[i]),xlab="")
  rug(log(w[,i]))
}
C<-w[w[,3]=="China",]
G<-w[w[,3]=="Germany",]
par(mfrow=c(1,2))
hist(C$Market.Value,20,main="Histogram of Market Value (China)",col=3,prob=T,ylim=c(0,0.07))
lines(density(C$Market.Value),lwd=2)
hist(G$Market.Value,20,,main="Histogram of Market Value (German)",col=2,prob=T,ylim=c(0,0.07))
lines(density(G$Market.Value),lwd=2)
```

本周“大牛”

- 弗朗西斯·高尔顿 (Francis Galton, 1822 年 2 月 16 日 - 1911 年 1 月 17 日), 英国科学家和探险家。他曾到西南非洲探险, 因树立功绩而知名并被选为英国皇家地理学会会员, 三年后又入选英国皇家学会, 晚年受封为爵士。他的学术研究兴趣广泛, 包括人类学、地理、数学、力学、气象学、心理学、统计学等方面。他是查尔斯·达尔文的表弟, 深受其进化论思想的影响, 把该思想引入到人类研究。他着重研究个别差异, 从遗传的角度研究个别差异形成的原因, 开创了优生学。他关于人类官能的研究开辟了个体心理和心理测验研究的新途径。